Lethetown: sociedades artificiales con memoria imperfecta. Una semana de juego con dos semillas y la primera validación real de la fase de aprendizaje

Resultados de dos partidas paralelas de 168 horas, incidencias, correcciones propuestas y hoja de ruta hacia la economía

Jaume • Proyecto Lethetown
https://github.com/jaume768/Lethetown

Resumen. Lethetown es un pueblo virtual de veinte habitantes gobernados por modelos de lenguaje y por mecanismos programados de memoria, psicología, aprendizaje y acción. Sus vecinos olvidan, reconstruyen recuerdos, confunden fuentes, practican oficios, se enseñan unos a otros y se cuentan saberes que se deforman. Este informe actualiza la versión 4.0 con la *tercera partida con modelos reales*: dos mundos en paralelo (semillas 7 y 13) durante siete días de juego, en un pueblo del interior de Mallorca en abril de 2002, ya con euros. Es la validación de la fase de aprendizaje que la versión anterior pedía. Las dos partidas costaron 18,38 dólares (1,31 por mundo y día, un 20 % menos que la segunda partida) y produjeron 4.530 frases en 1.125 conversaciones. Las intenciones cumplidas pasan del 46 % al 73–78 %, aparecen 101 proyectos nuevos y los primeros abandonos con motivo, hay 180 sesiones de enseñanza y 37 saberes transmitidos, y ninguna persona inventada se convierte en saga. Una semana deja ver también fallos que dos o tres días ocultaban: la estabilidad de la memoria crecía sin tope hasta desbordar la base de datos, la Batch API no se usaba, las metas vitales se cumplían contando proyectos (Leo «encuentra» el pez gigante sin encontrarlo), todo el pueblo aprende a cocinar, la deriva de personalidad empuja a todos en la misma dirección y, por diseño, ningún saber podía perderse en siete días. Se formalizan los mecanismos nuevos, se proponen diez correcciones (fase 3.5) y se actualiza la hoja de ruta hacia la economía.

Palabras clave: agentes generativos; memoria artificial; olvido; reconsolidación; psicología computacional; simulación social; aprendizaje; evolución cultural; replicación con semillas.

1. Introducción

1.1. Tres partidas para decir una frase

Julián lleva tres partidas intentando decirle a su hija Inés que le da miedo quedarse solo cuando ella se vaya a estudiar a Palma. En la segunda partida el motor contó sus conversaciones y dio la meta por cumplida, aunque él seguía aplazando el tema («Mañana hablamos de Palma. Con calma. . . »). En la semilla 13 de la tercera, lo intenta el día 2, vuelve a intentarlo en la cena del día 3 y, el día 5 a las 20:16, lo dice: «Inés. . . me da miedo quedarme solo. Si no es molestia». Ella responde: «Ya, papá. Pues no te quedes solo, joder. Cenamos juntos, ¿vale?». Esa noche la consolidación comprueba la meta con la frase registrada y la confirma [13].

En la misma semana, Leo, de diez años, «consigue» su meta vital de encontrar el pez gigante del lago en los dos mundos. Al día siguiente sigue proponiéndose ir a pescarlo con la red. Las dos escenas resumen esta versión: una semana basta para que aparezcan trayectorias con sentido, y también para que se noten los atajos de la medida.

1.2. Contribución y alcance

Este informe aporta cinco cosas:

1. La formalización de los mecanismos nuevos o corregidos: tope de estabilidad, aprendizaje con multiplicadores, olvido de habilidades, fidelidad de los saberes y deriva de la personalidad.
2. Los resultados de dos partidas reales de 168 horas con semillas distintas.
3. Su comparación con las dos partidas anteriores.
4. Diez correcciones, cada una con la métrica que debe verificarla.
5. El diseño del siguiente estudio y la hoja de ruta actualizada.

Como en versiones anteriores, *emergente* significa no guionizado; no implica conciencia ni conducta equivalente a la humana.

2. Antecedentes y método

La arquitectura parte de los agentes generativos de Park y colaboradores [1]: un flujo de observaciones, recuperación por recencia, importancia y relevancia, reflexión y planificación. Lethetown añade mecanismos inspirados en el olvido [2], la reconstrucción [3], la reconsolidación [4] y la emoción [5]. La fase 3 añade además práctica con rendimientos decrecientes [7], transmisión con variación [9] y deriva lenta de rasgos [8]. Todos los coeficientes son decisiones de ingeniería, no parámetros clínicos.

Se mantienen tres niveles de evidencia:

- **Observado**: una partida real registra cifras y episodios.
- **Implementado**: existe en el código y en las pruebas.
- **Propuesto**: solo está en este informe o en la hoja de ruta.

Hay cuatro partidas documentadas:

- E1, de 48 h, el 30 de octubre de 2026 [11];
- E2, de 72 h, el 31 de octubre [12];
- E3-s7 y E3-s13, de 168 h cada una, en paralelo el 3 y 4 de noviembre [13, 14].

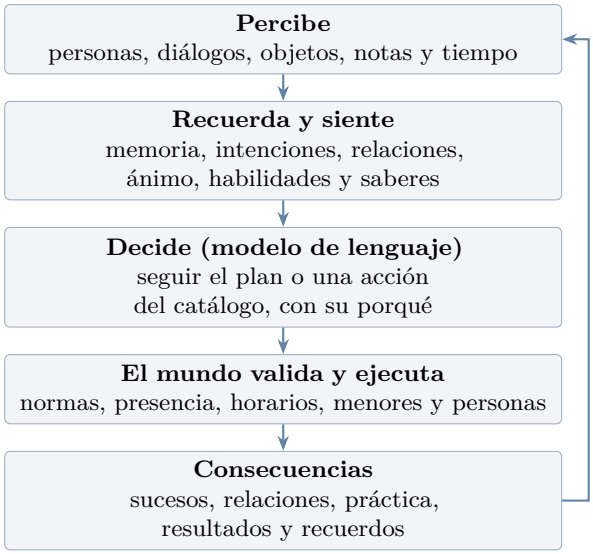


Figura 1: Ciclo de un habitante. La IA propone; el mundo verifica y produce consecuencias que vuelven a percibirse. En la fase 3, la práctica y los saberes cierran el ciclo por el lado de las consecuencias.

Los datos brutos de E3 están fuera de git. El análisis de este informe usa `analysis.json`, la comparación `study:analyze s7 s13` y los extractos por semilla [15].

3. Cómo funciona un habitante

3.1. Un mundo con reglas, ahora en 2002

Hay veinte vecinos de 10 a 82 años en un pueblo inventado del interior de Mallorca. El día 0 es el lunes 15 de abril de 2002. El mundo pasó de 1996 a 2002 al preparar la economía: con pesetas los precios eran cifras grandes («un café, cien pesetas») que el modelo y el analista tenían que convertir. El euro, en circulación desde enero, da precios pequeños y comparables. Se conserva casi todo lo que se buscaba con 1996: móviles sencillos con SMS, internet lento y de pocas casas, carretes y nada de redes sociales [10, 20].

El mapa tiene casas privadas, locales con horario, plaza, café, taberna, consultorio, escuela, huerto, lago y jardín. La simulación separa dos capas (Fig. 1):

- las reglas programadas controlan el tiempo, el movimiento, la memoria, las necesidades, los permisos y los efectos;
- el modelo de lenguaje decide, habla, planifica, resume y reflexiona.

El LLM elige una acción de un catálogo cerrado y el motor la valida. Por eso el lenguaje no puede crear directamente niveles de habilidad, progreso de metas, relaciones ni objetos.

3.2. Memoria imperfecta: seleccionar, olvidar y reforzar

Cada recuerdo conserva texto, esencia, importancia, emoción, fuerza, estabilidad, fuente y vínculos. La recuperación pondera cuatro rasgos y multiplica el resultado por la fuerza actual [19]:

$$\mathcal{R}(m,t) = S(m,t)\,\frac{1\,r + 1\,i + 1\,v + 0{,}5\,a}{3{,}5}, \qquad (1)$$

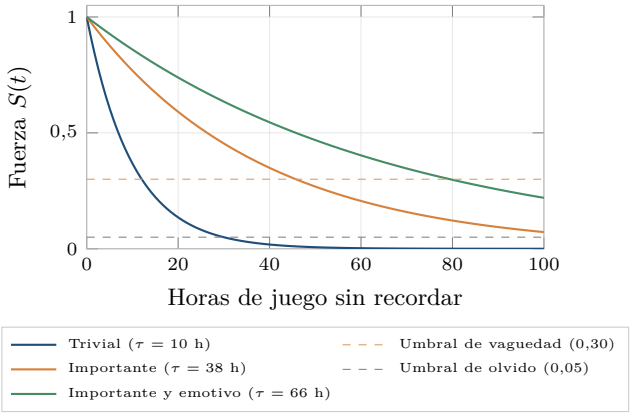


Figura 2: Decaimiento ilustrativo de tres recuerdos sin refuerzo. Los umbrales son los documentados; no son datos de una partida.

- $r = 0{,}995^{h}$ es la recencia (h = horas desde el último acceso);
- i es la importancia normalizada;
- v es la relevancia semántica;
- a es la coincidencia con el ánimo.

La fuerza decae con el tiempo de juego:

$$S(t) = S_0 \exp\!\left(-\frac{\Delta t}{\tau}\right). \qquad (2)$$

Por debajo de 0,05 el recuerdo no se recupera; entre 0,05 y 0,30 solo queda la esencia (Fig. 2).

Refuerzo y su tope. Evocar un recuerdo eleva su fuerza y multiplica su estabilidad. La tercera partida mostró que ese multiplicador, de 1,8 a 3,6, no tenía límite [13]. Tras el arreglo `9e87684`:

$$\tau_{n+1} = \min\!\big(k_n\,\tau_n,\ \tau_{\text{máx}}\big), \qquad k_n \in [1{,}8;\ 3{,}6], \qquad \tau_{\text{máx}} = 87.600\ \text{h}, \qquad (3)$$

es decir, diez años de juego. El número de evocaciones necesarias para llegar al tope es

$$n^{*} = \left\lceil \frac{\ln(\tau_{\text{máx}}/\tau_0)}{\ln k} \right\rceil, \qquad (4)$$

que con $\tau_0 = 24$ h y $k = 1{,}8$ da $n^{*} = 14$. Lo que se evoca en cada decisión, como las metas, puede llegar ahí en un día de juego (§6.9).

La recuperación también puede producir:

- **reconsolidación**: una versión nueva que conserva la anterior;
- **confusión de fuente**: «me lo contó X» pasa a «lo viví».

Durante el sueño se consolida lo importante, se crean reflexiones y se debilita lo trivial. La memoria tiene un presupuesto de 4.000 tokens por agente: al superarlo se resume o se descarta según reglas.

3.3. Psicología, relaciones y compromisos

Cada vecino tiene:

- rasgos de los Cinco Grandes y un perfil de memoria según edad y rasgos;

- ánimo en dos dimensiones;
- necesidades de energía, hambre y compañía.

Las relaciones no son recíprocas: cada ficha guarda afinidad, confianza, familiaridad y tipo de vínculo.

Desde la corrección 2.5, las relaciones progresan de forma amortiguada y las intenciones tienen un tope de ocho abiertas. Las promesas parecidas se fusionan y las poco importantes caducan. Las metas cualitativas solo se confirman de noche, contrastándolas con frases registradas [17, 21]. El `PersonGuard` sustituye por «alguien» los nombres de personas que no existen [20].

3.4. Habilidades: práctica, maestros y olvido

Hay catorce habilidades: cocina, panadería, café y barra, huerto, pesca, arreglos, fotografía, dibujo, música, enseñanza, cuidados, negociación, narración e idiomas. Las mide el motor según lo que cada uno *hace* (el objeto, la actividad o una sesión), nunca según lo que dice el LLM [18]. La curva de progreso es exacta:

$$L(h) = 1 - (1 - L_0)\, e^{-r\, m\, h}, \qquad m = m_M\, m_E\, m_A, \quad (5)$$

- $r = 0{,}02\ \mathrm{h}^{-1}$ es el ritmo base;
- $m_M = 2$ con un maestro que le saque 0,2 de nivel;
- $m_E = 1{,}3$ para menores de 18 años y 0,7 para mayores de 65;
- $m_A \geq 1$ crece con la apertura.

Las horas necesarias para alcanzar un nivel L son

$$h(L) = \frac{1}{r\, m}\, \ln \frac{1 - L_0}{1 - L}, \quad (6)$$

de modo que pasar de 0 a 0,5 cuesta 34,7 h con $m = 1$. Tras tres días sin práctica empieza el olvido:

$$\begin{aligned} L_d &= F + (L^* - F)\, 0{,}99^{\,d-3} \quad (d > 3), \\ F &= p\,(0{,}3 + 0{,}5\, p), \end{aligned} \quad (7)$$

donde p es el máximo alcanzado. El nivel también afecta a lo que sale de las manos:

$$\begin{aligned} P_{\text{arreglo}} &= 0{,}35 + 0{,}6\, L, \\ Q &= 0{,}7\, L + 0{,}3\, \varepsilon, \qquad \varepsilon \sim U(0{,}1). \end{aligned} \quad (8)$$

Las etiquetas son principiante ($< 0{,}2$), se defiende ($< 0{,}45$), bien ($< 0{,}7$) y con maestría.

3.5. Saberes del pueblo y deriva de la personalidad

Las semillas contienen 24 saberes: recetas, técnicas, canciones, historias y lugares. Cada portador guarda su versión, su fidelidad y su fuente. Al contarse pueden perder elementos o cambiarlos por variantes previstas, sin texto libre del LLM. La falta de uso reduce la fidelidad:

$$f(d) = f_0 - 0{,}012\ \max(0, d - 5), \quad (9)$$

y el saber se pierde para el pueblo cuando ningún portador supera 0,25. Con $f_0 = 0{,}95$, la pérdida exige unos $5 + (0{,}95 - 0{,}25)/0{,}012 \approx 63$ días sin que nadie lo use. En una semana era imposible por construcción (§6.4).

La personalidad deriva una vez por semana: como mucho 0,02 por rasgo y semana, y nunca más de 0,15 respecto a la semilla. Alcanzar el tope requiere al menos siete u ocho semanas [8].

3.6. Arquitectura reproducible y protección

Cada capacidad del mundo es un módulo `SimSystem` con sus acciones, su estado, sus instantáneas y sus métricas. La API y los trabajadores de simulación se ejecutan por separado, sobre PostgreSQL. Los menores tienen protección en capas:

- reglas del mundo;
- restricciones de encuentros y enseñanza;
- un `MinorGuard` que bloquea por precaución cuando no puede comprobar un texto.

No es una garantía absoluta [22].

4. Diseño de la tercera partida

4.1. Condiciones

Se ejecutaron dos mundos a la vez, cada uno con los veinte vecinos y bases de datos nuevas, con semillas 7 y 13.

- **Modelos**: Claude Haiku 5.5 para decisiones, importancia, fichas sociales, reconsolidación y resúmenes; Claude Sonnet 5.5 para planes, consolidación y crónica.
- **Duración**: del día 0 a las 06:50 al día 7 a las 06:50, es decir, 168 h de juego.
- **Velocidad**: ×10 de día y noche rápida a ×360.
- **Configuración**: Batch API para la consolidación y la crónica, modo demostración activo y `LLM_CONCURRENCY=8`.
- **Código**: rama `chore/estudio-semana`, creada desde `main` en `d5801ce`.
- **Vigilancia**: cada 30 minutos reales se revisaron coste, errores, memoria del proceso, `PersonGuard` y moderación [14].

4.2. Incidencias durante la partida

1. **Clave inválida** (401). Se paró a los diez minutos de juego, sin gasto, y se empezó de cero.
2. **Falsa alarma de coste** en el día 0 a las 23:00. La vigilancia extrapolaba el gasto justo después de pagar la consolidación y daba 2,52 dólares por día; el día entero costó 1,74. Al revisarlo apareció un fallo real: Anthropic rechazaba todos los lotes porque no admite el parámetro `fallbacks`, así que la consolidación se pagaba a precio completo. Se arregló en `ad112f2`.
3. **Ticks perdidos** en el día 3 a las 15:30: 20 en s13 y 6 en s7. Postgres rechazaba recuerdos con una estabilidad de $3{,}8 \cdot 10^{38}$ h, fuera del rango de `real`. Se arregló con la ecuación (3).

Cada parada duró unos 15 minutos reales y los mundos se reanudaron desde su instantánea. Ninguna obligó a descartar la partida.

4.3. Cómo leer las comparaciones

La Tabla 1 reúne las cuatro partidas, pero entre ellas cambian a la vez la duración, el mundo, las reglas y los personajes. Por eso no permite inferencias causales.

Con dos semillas se puede dar, al menos, la semisuma $\bar{x}$ y la semidiferencia ρ ($\bar{x} \pm \rho$). Por ejemplo:

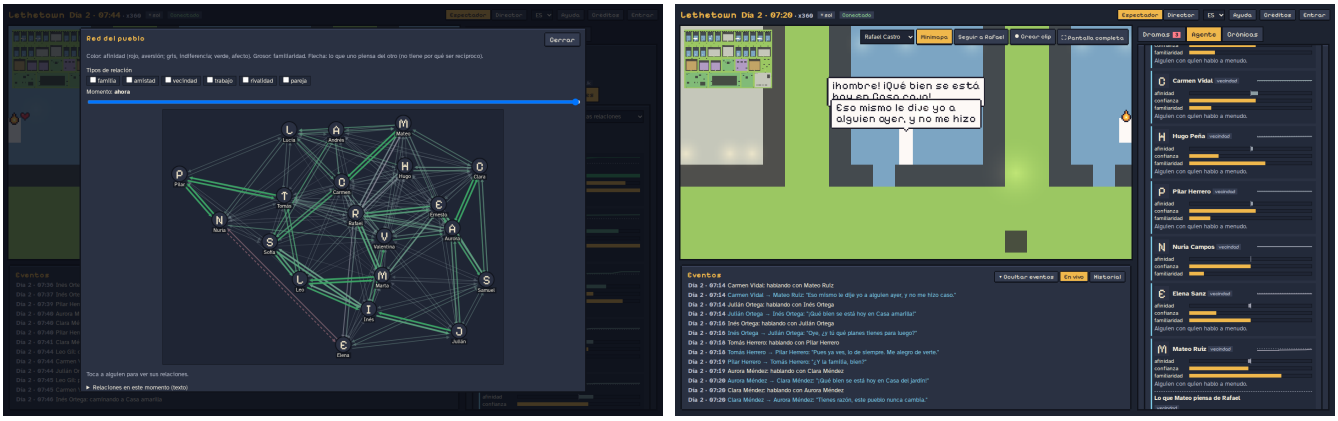


Figura 3: Interfaz de Lethetown. Izquierda: red de relaciones (color, afinidad; grosor, familiaridad). Derecha: relaciones del vecino seleccionado, con la ficha recíproca y su evolución. Ilustran las relaciones y la observación social de §3.3 y §6.6; no son capturas de la tercera partida.

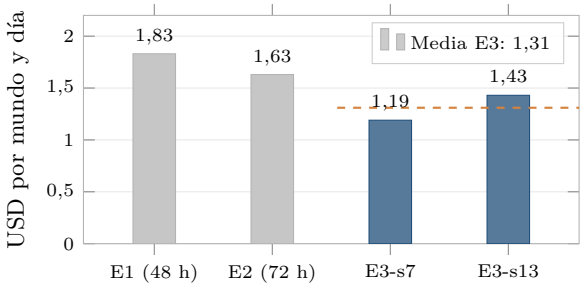


Figura 4: Coste por mundo y día de juego. La media de E3 es la cifra comparable: s7 se benefició de la caché que escribió s13.

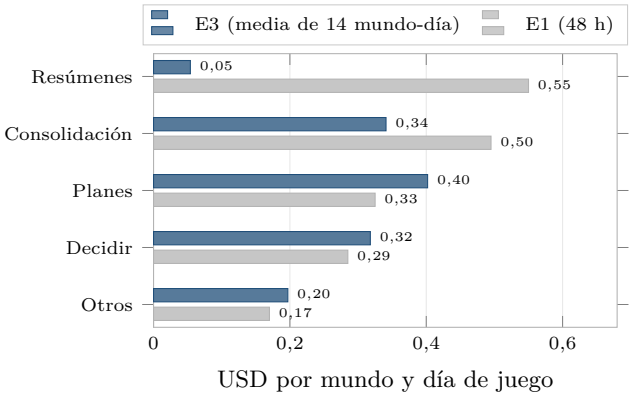


Figura 5: Coste por tarea, normalizado por mundo y día. «Otros» agrupa importancia, fichas sociales, reconsolidación, crónica y moderación. E2 no se incluye porque solo constan su consolidación (0,72 dólares al día) y sus resúmenes (0,05).

- intenciones cumplidas: $75{,}5 \pm 2{,}5$ %;
- cobertura de la red: $41{,}4 \pm 1{,}9$ %.

Es un rango entre dos réplicas, no un intervalo de confianza.

5. Coste y tiempo real

5.1. Coste por mundo y día

Las dos semillas comparten la caché de prompts: tienen los mismos personajes, la misma cuenta y el mismo prompt fijo, y planifican en el mismo segundo de cada mañana. El coste de una llamada depende de la fracción ρ_t de la entrada leída de caché:

$$\bar{c}_t = T_t^{\text{in}}\left[(1-\rho_t)\,p_{\text{in}} + \rho_t\,p_{\text{lect}}\right] + T_t^{\text{out}}\,p_{\text{out}}, \qquad C = \textstyle\sum_t n_t\,\bar{c}_t. \tag{10}$$

s13 escribió casi toda la caché del plan (564.000 tokens) y s7 la leyó (652.000 frente a 242.000 tokens). En el plan, s7 tuvo un 63 % de lectura de caché y s13 un 23 %: 1,45 céntimos por llamada frente a 2,57. Por eso el reparto entre semillas es arbitrario y la cifra honesta es la suma: **18,38 dólares, 1,31 por mundo y día** (Fig. 4). Un mundo solo costaría como s13, unos 1,4 dólares al día.

5.2. En qué se va el dinero

En E1 el gasto dominante eran los resúmenes de memoria. Después de las fases 0–2.5 casi desaparecen y el plan pasa a ser la tarea más cara (31 %), por delante de la consolidación (26 %) y de las decisiones (24 %) (Tabla 2, Fig. 5). Las decisiones son ya 10.655 llamadas y siguen siendo baratas gracias a la caché (74–75 %).

5.3. La Batch API, por fin medida

La noche 0 se pagó a precio completo porque la Batch API rechazaba los lotes: 1,19 dólares entre las dos semillas. Las noches 1 a 6, ya con lotes, costaron 0,60 dólares de media. Por llamada, s7 bajó de 3,3 a 1,2 céntimos (lote más caché ajena) y s13 de 2,7 a 1,7 (Fig. 6). Es el primer ahorro de Batch observado y no solo previsto.

5.4. Tiempo real y noche rápida

El tiempo real es la suma de cada tramo de juego dividido por su velocidad, $t_{\text{real}} = \sum_i \Delta t_i / v_i$. A $\times 10$ constante, un día cuesta 2,4 h reales. Con noche rápida costó 1,8 h, y la noche bajó de 51 a 11–17 minutos reales:

- de 22:00 a 23:15–00:40 el reloj va a $\times 10$ mientras se consolida en lote y se escribe la crónica;
- después, unos 70 segundos reales a $\times 360$ hasta las 06:30.

Una semana de juego cabe en 12,5 h reales en lugar de 16,8. En 12 de las 14 noches hubo una sola subida y una sola bajada de velocidad. Nadie despertó con la consolidación a medias.

Tabla 1: Indicadores de las cuatro partidas con modelos reales. Las duraciones y los mundos difieren: la comparación es descriptiva. En E3 el coste por semilla está repartido de forma arbitraria por la caché compartida (§5.1).

Indicador	E1 (48 h)	E2 (72 h)	E3-s7 (168 h)	E3-s13 (168 h)
Mundo	pueblo genérico	Mallorca 1996	Mallorca 2002	Mallorca 2002
Coste total (USD)	3,65	4,90	8,35	10,03
Coste por mundo y día (USD)	1,83	1,63	1,19	1,43
Llamadas al LLM (por día)	3.953 (1.977)	6.564 (2.188)	15.304 (2.186)	14.364 (2.052)
Frases (por día)	1.043 (522)	1.596 (532)	2.421 (346)	2.109 (301)
Conversaciones (turnos medios)	204 (—)	312 (5,1)	600 (4,0)	525 (4,0)
Espera media de respuesta (s reales)	10,1	10,3	11,0	10,1
Parejas que hablaron (%)	31	36	39,5	43,2
Gini de frases por agente	—	0,27	0,31	0,25
Intenciones propuestas / cumplidas	359 / 197	597 / 274	705 / 518	617 / 479
cumplidas (%)	55	46	73	78
Acuerdos hablados convertidos en acción	—	16	49	39
Cambios de tipo de relación	—	36	73	47
Reconsolidaciones	528	788	1.652	1.557
Recuerdos archivados	2.747	4.522	10.830	9.745
Metas conseguidas / abandonadas	—	27 / 0	68 / 2	58 / 4
Metas vitales cumplidas (de 20)	—	0	7	5
Sesiones de enseñanza / ayudas	—	—	99 / 35	81 / 20
Saberes aprendidos / perdidos	—	—	21 / 0	16 / 0
Errores del LLM (ticks perdidos)	30	0	5 (6)	3 (20)
Anacronismos detectados	—	0	0	0

Tabla 2: Coste por tarea en E3 (suma de las dos semillas) y lectura de caché.

Tarea (modelo)	Llamadas	USD	Caché s7 / s13
Plan (Sonnet)	280	5,63	63 / 23 %
Consolidación (Sonnet, Batch)	280	4,78	40 / 20 %
Decidir (Haiku)	10.655	4,45	74 / 75 %
Importancia	7.695	1,11	93 / 93 %
Fichas sociales	2.652	0,89	80 / 82 %
Esencias y resúmenes	4.620	0,76	87–92 %
Reconsolidación	3.382	0,64	94 / 93 %
Crónica (Sonnet)	14	0,11	0 %
Moderación y otras[a]	90	0,01	—
Total	29.668	18,38	

[a] Obtenida por diferencia con el total de la Tabla 1.

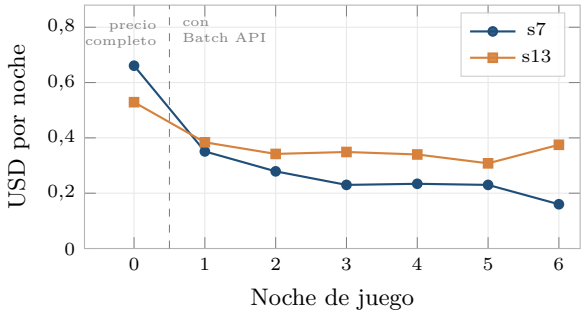


Figura 6: Coste de la consolidación nocturna (20 llamadas por noche y mundo). La caída de la noche 0 a la 1 es el efecto de los lotes; la diferencia restante entre semillas es la caché compartida.

6. Hallazgos

6.1. Metas: proyectos nuevos, abandonos con historia y un atajo

Lo que fallaba en E2 ahora funciona:

- **Proyectos nuevos**: hay 56 en s7 y 45 en s13, frente a ninguno en E2, además de 27 y 33 pasos nuevos. Algunos tienen muy buena pinta: Samuel quiere que Ernesto se revise el pecho y la tensión, y Aurora, enseñar a Clara a hacer pan con aceite y tomate.
- **Frustración**: crece de forma gradual hasta 0,19 y 0,30 (0,06 en E2) y produce los primeros abandonos (Fig. 7).

Los abandonos tienen motivo:

- **Rafael, en s7**, deja dos proyectos de la taberna con frustraciones de 0,81 y 0,85 y acaba la semana con la frustración más alta del pueblo.
- **Sofía, en s13**, deja «Que Inés vuelva a clase con ganas» con 0,96.
- **Andrés** hace el único cambio de rumbo razonado: abandona llevar el atlas a la escuela porque «Sofía se lo llevó ella».

Las confirmaciones nocturnas de metas cualitativas son exigentes, no complacientes: 0 de 14 en s7 y 2 de 9 en s13, siempre con motivos concretos. El problema está en las **metas vitales**: se cumplieron 7 en s7 y 5 en s13, todas por el criterio de «conseguir 4 de sus proyectos». Contar proyectos no es conseguir:

- Leo «encuentra» el pez en los dos mundos y sigue buscándolo;
- Valentina «descubre qué pasó con su abuela» en s13, el día 5, y el día 6 sigue preguntando por Alma;

- nadie se va del pueblo, aunque Clara llega a 0,84 de «Estudiar enfermería en Palma»;
- la meta vital de Inés queda aplazada en las dos semillas porque es menor de edad.

6.2. Intenciones: el tope y la fusión funcionan

Las intenciones cumplidas suben del 46 % en E2 al 73 % en s7 y al 78 % en s13 (Fig. 8). Contribuyen tres mecanismos:

- la **fusión**, que juntó 274 y 168 intenciones parecidas («pagarle a Rafael lo que le debo» equivale a «devolverle a Rafael el dinero que le debo»);
- el **tope de ocho**, que descartó 137 y 63;
- la **caducidad**, casi irrelevante: solo 3 por mundo.

Hugo es quien más choca con el tope: deja de lado «tocarle una canción a Rafael a cambio de la deuda» por una cita. La deuda con Rafael, que ahora son «cien euros de hoy», vuelve a ser el hilo más largo del pueblo, como en las dos partidas anteriores.

6.3. Habilidades: se aprende, pero todos aprenden lo mismo

Enseñar y ayudar sale con naturalidad: entre 6 y 21 sesiones al día, con 99 y 81 en total (66 y 58 terminadas) y 35 y 20 ayudas. Las parejas suelen tener sentido:

- Tomás enseña a pescar a Leo;
- Clara enseña a Rafael a vender;
- Valentina enseña fotografía a Inés.

Hay alguna excepción: en s7, Mateo y Hugo encadenan 17 eventos de enseñanza de café y barra, demasiados para una sola habilidad.

La curva (5) **se cumple.** En s7, los adultos sin maestro que cocinan tres veces al día pasan de 0,30 a 0,53–0,58 con unas 19–23 horas de práctica. La ecuación predice 0,55 para Nuria (22,6 h); se observó 0,58, y la diferencia la explica el multiplicador de apertura (Fig. 9). Con maestro, los jóvenes cambian de etiqueta en una semana:

- Leo, en cocina: de 0,05 a 0,56–0,61;
- Inés, en fotografía: de 0,35 a 0,65–0,70, con maestría en s13;
- Leo, en pesca: de 0,10 a 0,36–0,38.

El problema es que *casi todo el pueblo sube en cocina*. Es práctica de hacer, como se quería, pero iguala a todos en lo mismo.

El olvido es lento, como se quería: unos −0,002 por semana. Pero el día 4 a las 00:00 bajan de etiqueta 8 habilidades por mundo a la vez (Fig. 10). No es olvido real: es el primer repaso tras tres días sin práctica, y los valores de las semillas que estaban justo en el umbral (0,20, 0,45, 0,70) lo cruzan por milésimas.

Lo que se fabrica se acumula sin uso: 49 cestas de verdura, 32 dibujos, 14 panes y 11 fotos en s7, y 38, 10, 16 y 15 en s13. Nadie se come el pan.

6.4. Saberes: se transmiten bien, casi no se deforman y no se pierden

Se transmitieron 21 saberes en s7 y 16 en s13, con una fidelidad media de lo aprendido de 0,97 y 0,92. Solo uno de 37 se deformó: Inés aprende de Ernesto «Las cartas sin remitente» con la variante «siempre en sobre blanco». Ninguno se perdió. Según (9) no era posible: harían falta unos 63 días sin uso. Que no se perdiera ninguno no aporta evidencia sobre el mecanismo; hay que cambiar el ritmo o la duración.

Además, el motor ofrece `share_lore` a quien ya conoce el saber. Aurora le cuenta a Clara «El verano en que Alma se fue» 6 veces en s7 y 11 en s13.

La historia que sugerían las semillas sale a medias. En s7, Valentina aprende de Aurora lo de Alma, pero Aurora, cuya memoria empeora, ya no puede ayudarla. El día 3 aún dice: «Alma era pura risa, ay, criatura. Se marchó del pueblo un día y nunca más supe de ella… ». El día 4 ya no se acuerda: «Ni idea, criatura. De Alma ya no me acuerdo de eso».

6.5. Personalidad: una deriva igual para casi todos

Los veinte vecinos de cada mundo cambian una vez, en el repaso semanal, y como mucho ±0,02 por rasgo, como prevé el diseño (§3.5). El problema es que casi todos se mueven en la misma dirección:

- más apertura (hasta +0,016);
- más responsabilidad (hasta +0,020);
- menos neuroticismo (hasta −0,020).

En una semana buena para casi todos (aprender, enseñar, cumplir metas), todo empuja igual. Solo Rafael, el de los dos abandonos, gana inquietud (+0,014). La deriva funciona como mecanismo, pero todavía no diferencia a nadie.

6.6. Red social y conversaciones

Para medir la red se usan dos indicadores: la cobertura y el índice de Gini sobre las frases por agente x_i.

$$\text{cobertura} = \frac{P}{\binom{20}{2}} = \frac{P}{190}, \qquad G = \frac{\sum_i \sum_j |x_i - x_j|}{2\,n^2\,\bar{x}}. \tag{11}$$

Hablan menos que en E2 (346 y 301 frases al día frente a 532), porque las fichas suben más despacio desde la corrección 2.5. Aun así, la red se abre más: un 39,5 % y un 43,2 % de las parejas posibles, con un Gini de 0,31 y 0,25 (Fig. 11). Ningún vecino queda con menos de dos interlocutores en la semana.

Una rivalidad política que nadie sembró. En las dos semillas, Elena, que quiere ganar las municipales, choca con quien difunde el rumor de Promociones Llevant:

- en s7, con Ernesto, con afinidad −0,80 («Antes de nada, dime de dónde sacas lo de Llevant»);
- en s13, con Rafael, con −0,84.

La rivalidad de Nuria y Elena por la casa en venta se mantiene en las cuatro partidas, mientras que Rafael y Mateo vuelven a reconciliarse. Los cambios de tipo de relación son sobre todo de vecino a amigo (45 y 28 casos).

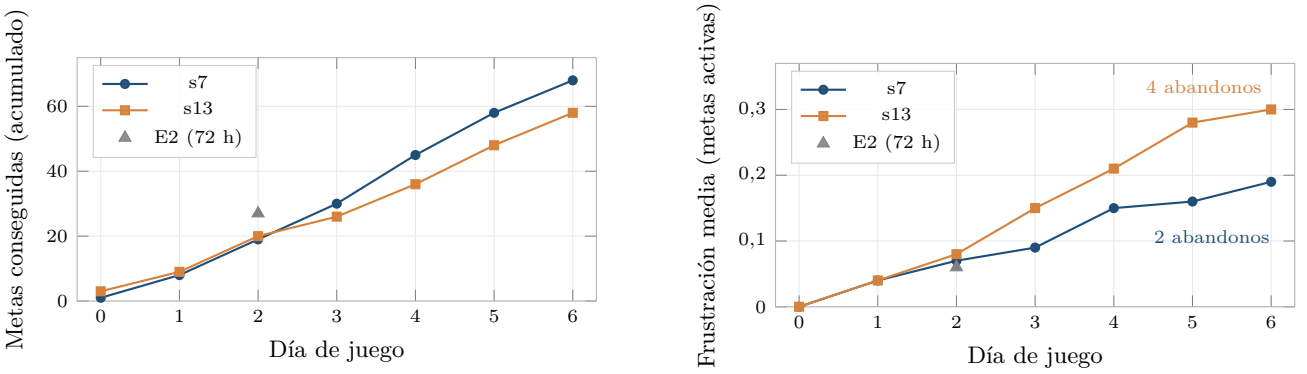


Figura 7: Metas en las dos semillas. Izquierda: metas conseguidas acumuladas, incluidos proyectos y pasos. Derecha: frustración media de las metas activas. A los tres días de E2 la frustración apenas se movía; con siete días ya produce abandonos, aunque no masivos.

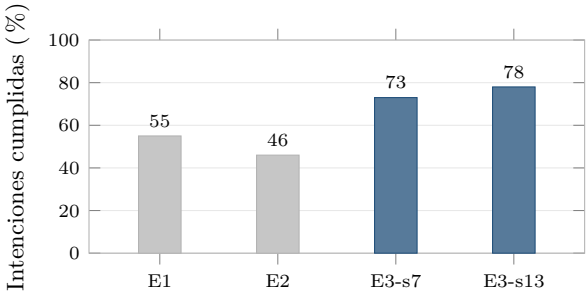


Figura 8: Cociente entre intenciones cumplidas y propuestas. No es una cohorte cerrada: algunas intenciones siguen abiertas al terminar.

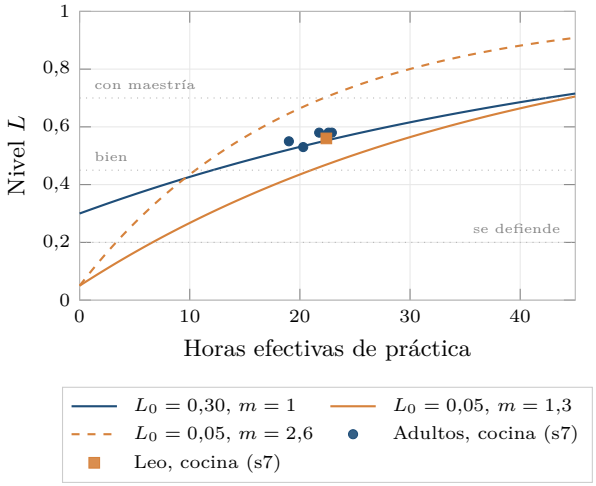


Figura 9: Curva teórica (5) frente a niveles observados tras una semana. Leo, joven y con maestro parte del tiempo, queda entre las curvas sin maestro y con maestro.

6.7. PersonGuard: casi no interviene, y cuando lo hace suele equivocarse

El `PersonGuard` repitió con aviso 3 de 5.514 decisiones en s7 y 9 de 5.141 en s13. De esas 12 repeticiones, solo una era una persona inventada de verdad: «la señora Pepa», otra vez en boca de Ernesto (Tabla 3). Su precisión es, por tanto, de $1/12 \approx 8\ \%$.

Entre los nombres sustituidos por «alguien» también hay ruido:

- siglas de estudios: «el BUP» aparece 8 veces;
- instituciones: «el Ajuntament»;
- infinitivos tras una coma en las listas del plan: «mi madre, Abrir», unos 20 casos.

Lo importante es que ninguna persona inventada se convierte en saga, como lo fue la Pepa en E2 con 23 recuerdos. La regla del prompt basta; lo que sobra es el ruido del detector. En el registro de conocimiento externo, «Fela» (Fela Kuti, de quien hablan Hugo y Samuel) supone 85 de las 146 referencias de s13.

6.8. Menores

Hubo cuatro bloqueos y los cuatro fueron falsos positivos entre familiares:

- Leo, de 10 años, a su madre: «¿Me das un beso?»; se bloquea en el recuerdo de cada uno de los dos;
- dos textos de Julián sobre su hija Inés.

El moderador no sabía que eran madre e hijo, y padre e hija. No hubo ningún contenido inapropiado.

Tabla 3: Las 12 decisiones repetidas por `PersonGuard` en E3.

Causa	Casos
Apodo de un vecino («Rafa» por Rafael)	7
Persona conocida por un saber o una semilla ajena (Alma, Francisca, Joana)	3
Siglas de estudios («la PAU»)	1
Persona inventada («la señora Pepa»)	**1**

6.9. Memoria: el refuerzo necesitaba un tope y un espaciado

Hubo 1.652 y 1.557 reconsolidaciones y unos 1.500 recuerdos archivados al día, como en E2. El hallazgo técnico más importante es el crecimiento sin tope de la estabilidad. Cada evocación la multiplicaba, y las metas, evocadas en cada decisión, acumularon hasta 142 evocaciones. Con $k = 1{,}8$, eso da una estabilidad del orden de 10^{37}–10^{38} h, por encima del máximo de un `real` de Postgres (Fig. 12).

El tope (3) evita el desbordamiento, pero no corrige el fondo del problema. Evocar algo cada diez minutos no debería consolidarlo igual que evocarlo una vez al día;

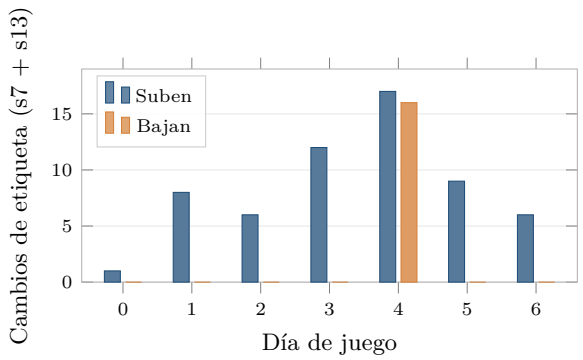


Figura 10: Hitos de habilidad por día. Las 16 bajadas del día 4 son un artefacto de los umbrales, no olvido; motivan la histéresis (13).

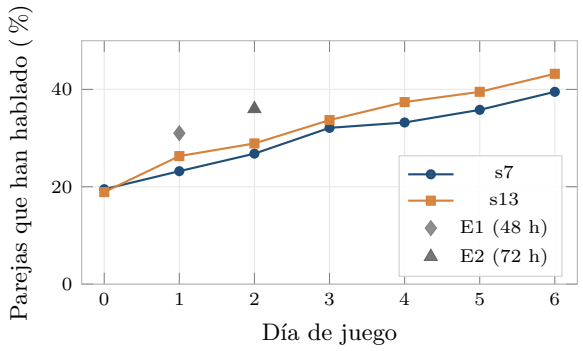


Figura 11: Proporción acumulada de las 190 parejas posibles que han conversado. La red sigue abriéndose al final de la semana, sin saturarse.

es el efecto de espaciado conocido en psicología [6]. Se propone que el multiplicador dependa del intervalo Δt desde la evocación anterior:

$$k(\Delta t) = 1 + (k_{\text{máx}} - 1)\left(1 - e^{-\Delta t/\tau_n}\right). \qquad (12)$$

Así, evocar algo de nuevo al minuto ($\Delta t \ll \tau_n$) casi no lo refuerza.

7. Dos semillas: lo que se repite y lo que no

Las cifras de las dos semillas se parecen mucho; las historias no (Tabla 4). Algunos elementos se repiten en las dos y en las partidas anteriores, lo que apunta al diseño y no al azar:

- la deuda de Hugo;
- la rivalidad entre Nuria y Elena;
- el choque de Elena con el rumor de Llevant;
- Aurora contando una y otra vez lo de Alma;
- Leo encontrando el pez sin encontrarlo;
- el apodo «Rafa».

Lo que cambia (quién abandona, quién se atreve a hablar) es lo que aporta la variedad.

8. Qué se corrige ahora: fase 3.5

Igual que E2 motivó la corrección 2.5, de E3 salen diez correcciones (Tabla 5). «Fase 3.5» es una etiqueta

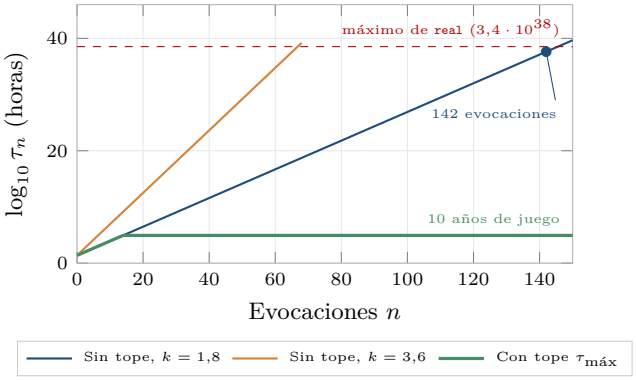


Figura 12: Crecimiento de la estabilidad con $\tau_0 = 24$ h, valor ilustrativo. Sin tope, las metas más evocadas llegaron al límite de la base de datos el día 3.

Tabla 4: Trayectorias que divergen entre semillas.

Tema	s7	s13
Rafael	Abandona dos proyectos de la taberna	Sigue a medias, sin abandonos
Julián e Inés	Julián esquiva el tema	Se lo dice y se confirma
Inés	Fotografía: de 0,35 a 0,65	Llega a 0,70, pero abandona el proyecto
Valentina	Aprende la historia de Alma	No la aprende, pero «cumple» su meta
Coste	8,35 USD (leyó la caché)	10,03 USD (la escribió)

editorial de este informe: todavía no existe como rama ni como hito en el repositorio. Dos de ellas ya están aplicadas: el tope de estabilidad y los lotes sin `fallbacks`. Para las etiquetas de habilidad se propone histéresis: la etiqueta sube al cruzar el umbral u_j y solo baja por debajo de $u_j - \delta$, con $\delta = 0{,}02$:

$$\text{baja} \iff L < u_j - \delta, \qquad \text{sube} \iff L \geq u_j. \qquad (13)$$

9. Hoja de ruta hacia una sociedad que evoluciona

9.1. Qué existe y qué sigue previsto

En Lethetown la evolución no consiste en entrenar los pesos del modelo. Lo que cambia es el estado del mundo y de sus habitantes: recuerdos, vínculos, metas, habilidades, saberes y, a largo plazo, instituciones y generaciones. Para hablar de evolución cultural hacen falta tres ingredientes [9]:

- **variedad**: E3 la confirma, porque las historias divergen entre semillas;
- **transmisión**: también confirmada, con 37 saberes y 180 sesiones de enseñanza;
- **presión**: todavía falta. Nadie pasa necesidad, el pan se acumula y la deuda de Hugo con Rafael, presente en las cuatro partidas, sigue sin poder comprobarse.

Eso es lo que debe aportar la economía (Fig. 13, Tabla 6).

Tabla 5: Correcciones de la fase 3.5: problema observado, cambio propuesto y métrica que debe verificarlo en el siguiente estudio.

Área	Observado en E3	Cambio	Métrica de verificación
PersonGuard	11 de 12 repeticiones son falsos positivos	Aceptar apodos y prefijos de vecinos; ignorar siglas e instituciones; tratar la coma como separador en las listas; contar como conocidos a quienes aparecen en un saber aprendido	Repeticiones ≤ 2 por semana; personas inventadas reales sin cambios
Menores	4 bloqueos, todos entre padres e hijos	Pasar el parentesco al moderador o no moderar lo familiar sin términos fuertes	0 falsos positivos familiares; ningún contenido inapropiado
Metas vitales	12 cumplidas contando proyectos	Exigir la confirmación nocturna del enunciado o un proyecto con su criterio	Ninguna meta «cumplida» que siga persiguiéndose al día siguiente
Saberes (repetición)	Aurora cuenta a Clara la misma historia hasta 11 veces	No ofrecer `share_lore` a quien ya lo sabe completo y lo oyó hace poco	Repeticiones por pareja y saber ≤ 2
Saberes (variación)	1 de 37 deformados y 0 perdidos (imposible en 7 días)	Más probabilidad de variante; revisar la gracia y el ritmo de (9) o alargar la partida	Deformados ≥ 10 %; tiempo de pérdida medible
Habilidades (umbral)	16 bajadas a la vez el día 4	Histéresis (13)	Sin bajadas simultáneas por umbral
Habilidades (cocina)	Todo el pueblo sube en cocina	Que comer cuente menos que cocinar algo de verdad, o un coste mayor por práctica	Dispersión de habilidades por oficio
Resultados	49 cestas de verdura sin usar	Consumo, regalo o venta (enlaza con la economía)	Inventarios estables
Personalidad	Deriva casi igual para todos	Pesar también conflictos, fracasos y soledad; que el perfil de memoria y el ánimo base sigan la deriva	Varianza de $\Delta\theta$ entre vecinos
Memoria	Evocar cada 10 min refuerza como una vez al día	Espaciado (12) sobre el tope (3)	Distribución de τ sin acumulación en $\tau_{\text{máx}}$
Estudios en paralelo	La caché compartida reparte el coste arbitrariamente	Sumar el coste conjunto o desfasar los arranques; añadir Fela Kuti y Bob Dylan a las referencias comunes	Coste por semilla comparable

9.2. Por qué la economía es la siguiente

E3 da tres motivos concretos para la economía. El primero es la deuda de Hugo: ya se habla de cantidades en euros, y un registro contable permitiría separar lo que se debe de lo que cada uno recuerda deber. El segundo son los resultados acumulados, que necesitan consumo o venta. El tercero es que la presión que falta saldría de la escasez de peces del lago y de la cosecha del huerto.

El repositorio ya prepara `buy_item`/`sell_item` sobre `Item.value`. Además, el cambio a 2002 permite leer y comparar los precios sin convertir.

Las fases siguientes se mantienen como en la versión 4.0:

- **Editor**: cambios validados del mundo, que los vecinos descubren como cualquier novedad.
- **Innovación**: combinaciones de prácticas con efectos medibles, no solo narradas.
- **Construcción**: obras visibles con licencia, materiales y plazos.
- **Ciclo vital**: transmisión entre generaciones. Es lo que permitiría observar la pérdida de saberes que una semana no deja ver, y desbloquearía las metas aplazadas de los menores.

10. Evaluación futura y reproducibilidad

Cuarto estudio (E4). Se propone repetir las condiciones de E3 con la fase 3.5 aplicada:

- siete días y dos semillas (7 y 13);
- cuentas separadas o arranques desfasados, para que el coste por semilla sea medible;
- un tercer mundo en ablación, por ejemplo sin olvido ni vaguedad, como primer paso hacia la comparación causal.

Con unos 1,4 dólares por mundo y día, E4 costaría unos 30 dólares y unas 12,5 h reales en paralelo. Una partida de 30 días, la duración mínima para observar pérdidas de saberes con los parámetros actuales, costaría unos 42 dólares por mundo.

Métricas. Se mantienen las cinco familias de la versión 4.0:

- fidelidad de la memoria;

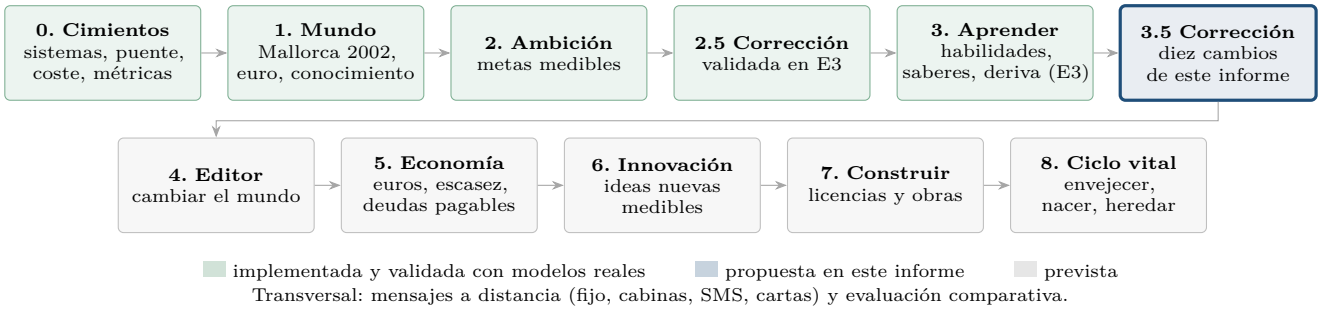


Figura 13: Hoja de ruta. Cada fase se apoya en las anteriores; tras cada una habrá una partida grabada y analizada.

Tabla 6: Estado del proyecto a 5 de noviembre de 2026. «Validada» significa observada en una partida real, no demostrada causalmente.

Fase	Enfoque	Estado
0	Cimientos y métricas	Validada (E2, E3)
1	Mundo y época (2002)	Validada (E3)
2	Metas medibles	Validada (E2, E3)
2.5	Correcciones de E2	Validada (E3)
3	Habilidades, saberes y deriva	Validada (E3, 1 semana)
3.5	Correcciones de E3	Propuesta
4	Editor del mundo	Prevista
5	Economía y recursos	Prevista; preparada
6	Innovación y adopción	Prevista
7	Construcción	Prevista
8	Ciclo vital y herencia	Prevista

- compromisos y metas, separando lo contado de lo confirmado;
- red social;
- aprendizaje y cultura;
- fiabilidad y coste.

Se añaden la métrica asociada a cada corrección (Tabla 5) y dos indicadores de diferenciación: la varianza de la deriva y la dispersión de habilidades por oficio. Para estimar causalidad siguen pendientes las ablaciones escalonadas:

- memoria sin olvido;
- con olvido y vaguedad;
- más psicología y relaciones;
- más metas;
- más aprendizaje.

Deben ejecutarse con varios replicados, al menos dos modelos y una evaluación humana ciega que separe verosimilitud de corrección factual.

Reproducibilidad. Cada estudio debe acompañarse de un manifiesto con:

- el SHA del código, en este caso `d5801ce` más `ad112f2` y `9e87684`;
- semilla, configuración, modelos y precios;
- las incidencias y los minutos de juego en que ocurrieron.

Los registros de E3 (`messages.jsonl`, `states.jsonl`, `bd/`) siguen fuera de git. Publicar `analysis.json` y `compare-s7-s13.log`, que no contienen información sensible, permitiría verificar cada cifra de este informe [15].

11. Limitaciones y conclusiones

Veinte personajes y dos semillas no demuestran representatividad social ni una memoria comparable a la humana. Las dos semillas comparten personajes y caché, así que no son réplicas independientes en coste. Los parámetros son decisiones de diseño, y varios resultados dependen de ellos de forma conocida: la pérdida de saberes era imposible y los cambios de etiqueta estaban en el umbral. Además, los errores de software pueden parecer conductas, como ya mostró el caso de Lucía en E1. La moderación de menores tiene falsos positivos documentados. Sigue siendo necesario separar con rigor lo que sucedió de lo que cada habitante cree recordar.

Una semana con dos semillas confirma lo que las partidas cortas solo insinuaban:

- las metas generan proyectos y abandonos con historia;
- las promesas se cumplen tres de cada cuatro veces;
- se enseña y se aprende con efectos medibles en el mundo;
- las historias divergen entre semillas mientras los conflictos sembrados persisten;
- todo ello a 1,31 dólares por mundo y día.

También muestra que medir no es conseguir (Leo y su pez) y que ciertos mecanismos necesitan más tiempo o más variedad para decir algo: la deriva, la deformación y la pérdida. El siguiente paso no es añadir sistemas sino aplicar la fase 3.5, verificarla en E4 y, con la presión de la economía, **observar si unas prácticas persisten más que otras**.

Referencias

[1] Park, J. S. et al. (2023). Generative Agents: Interactive Simulacra of Human Behavior. UIST; arXiv:2304.03442.

[2] Ebbinghaus, H. (1885). *Memory: A Contribution to Experimental Psychology.*

[3] Bartlett, F. C. (1932). *Remembering.* Cambridge University Press.

[4] Nader, K., Schafe, G. E. y LeDoux, J. E. (2000). Fear memories require protein synthesis in the amygdala for reconsolidation after retrieval. *Nature*, 406.

[5] Russell, J. A. (1980). A circumplex model of affect. *Journal of Personality and Social Psychology*, 39(6).

[6] Cepeda, N. J. et al. (2006). Distributed practice in verbal recall tasks: A review and quantitative synthesis. *Psychological Bulletin*, 132(3).

[7] Newell, A. y Rosenbloom, P. S. (1981). Mechanisms of skill acquisition and the law of practice. En *Cognitive Skills and Their Acquisition*. Erlbaum.

[8] Roberts, B. W., Walton, K. E. y Viechtbauer, W. (2006). Patterns of mean-level change in personality traits across the life course. *Psychological Bulletin*, 132(1).

[9] Mesoudi, A. (2011). *Cultural Evolution*. University of Chicago Press.

[10] Lethetown. Repositorio `https://github.com/jaume768/Lethetown`, rama `main`: README.md y CLAUDE.md, consultado el 5/11/2026.

[11] Lethetown (30/10/2026). Partida de estudio de 48 horas. `estudio/partida-2dias/ESTUDIO.md`.

[12] Lethetown (31/10/2026). Segunda partida: 72 horas, Mallorca 1996 y metas. `estudio/partida-3dias-mundo-metas/estudio2.md`.

[13] Lethetown (3–4/11/2026). Tercera partida: 7 días, dos semillas, Mallorca 2002. `estudio/semana-fase3/ESTUDIO.md`.

[14] Lethetown. Vigilancia de la partida de la fase 3. `estudio/semana-fase3/vigilancia.md`.

[15] Lethetown. `s7/` y `s13/analysis.{md,json}`, `compare-s7-s13.log`, `extract-s7.txt`, `extract-s13.txt` (fuera de git).

[16] Lethetown. `PROGRESS-APRENDIZAJE.md`.

[17] Lethetown. `PROGRESS-CORRECCION-2-5.md`.

[18] Lethetown. `docs/decisiones/skills.md` y `lore.md`.

[19] Lethetown. `docs/decisiones/memoria.md` y `psicologia.md`; `packages/agent-core/src/memory/config.ts`.

[20] Lethetown. `docs/decisiones/mundo.md` y `personas.md`.

[21] Lethetown. `docs/decisiones/metas.md` y `evolucion.md`.

[22] Lethetown. `docs/decisiones/menores.md`.

Documento divulgativo-técnico con estructura de artículo académico. No revisado por pares.